



بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

شبکه‌های عصبی کانولوشنی ترکیبی کوانتومی-کلاسیک-کوانتومی (QCQ-CNN)




Hybrid quantum-classical-quantum convolutional neural networks

مقدمه و انگیزه



محدودیت‌های کلاسیک




پتانسیل کوانتومی


- محدودیت **CNN** کلاسیک در فضاهای ویژگی پیچیده
- استفاده از **فضای هیلبرت** برای استخراج ویژگی‌های غنی‌تر
- **چالش نویز و کیوبیت‌های** محدود در سخت‌افزارهای فعلی
- **راهکار:** معماری ترکیبی برای تعادل پایداری و قدرت

عصر NISQ

$$\text{QCQ} = \text{Quantum} + \text{Classical} + \text{Quantum}$$



مرحله اول: فیلتر کوانتومی (Quanvolution)



- حرکت پنجره لغزان 2×2 روی تصویر
- کدگذاری زاویه (Angle Encoding) پیکسل‌ها به کیوبیت
- استفاده از مدارهای تصادفی با پارامترهای ثابت
- نگاشت غیرخطی به فضای ویژگی کوانتومی


مرحله اول: فیلتر کوانتومی (Quanvolution)

ضرب تانسوری (Tensor Product)
عملیات موازی روی تمام N کیوبیت.

$$\mathcal{S}(x) = \bigotimes_{i=1}^N RY(\pi x_i)$$

گیت چرخش Y
چرخش حول محور Y در کره بلاک.

نگاشت داده
مقدار پیکسل (0 تا 1) به زاویه
(0 تا π) تبدیل می‌شود.



مرحله اول: فیلتر کوانتومی (Quanvolution)

عمق مدار (Circuit Depth)
تکرار لایه‌ها به تعداد L بار.

چرخش‌های محلی
انتقال ویژگی‌ها به فضای برداری جدید.

برهم‌کنش سراسری
گیت‌های دو-کیوبیتی
روی همسایه‌ها.


$$U_{quanv}(\bar{\theta}) = \prod_{l=1}^L \left[\left(\bigotimes_{i=1}^N RZ(\theta_{i,l}) RY(\theta'_{i,l}) \right) \cdot \prod_j CNOT_{j,j+1} \right]$$

ترم CNOT مسئول ایجاد همبستگی کوانتومی است.

چرا این مهم است؟

- اطلاعات مکانی: در تصاویر، لبه‌ها و بافت‌ها در رابطه بین پیکسل‌ها نهفته هستند، نه داخل یک پیکسل.
- وابستگی: گیت CNOT وضعیت یک پیکسل را به همسایه‌اش وابسته می‌کند.
- نتیجه: شناسایی الگوهای فضایی (Spatial Patterns) که در تک‌پیکسل وجود ندارند.


توجیه پارامترهای ثابت در لایه اول



- کاهش سرشار محاسباتی
- حذف پیچیدگی
- نقش این لایه
- اجتناب از Barren Plateaus
- مقاومت در برابر نویز
- یادگیری نامناسب

مرحله دوم: لایه کلاسیک و کاهش ابعاد

- کاهش ابعاد داده‌های ورودی
- ایجاد گلوگاه اطلاعاتی برای مدار کوانتومی بعدی
- پایداری آموزش و جلوگیری از نویز



کد کردن داده کلاسیک روی طبقه بند QNN

• هدف: انتقال داده‌های کلاسیک به فضای

هیلبرت (Hilbert Space) با ابعاد بالا.

• چرا ZZ؟

- این نقشه ویژگی برای داده‌های

طبقه‌بندی (Classification)

طراحی شده است.


- علاوه بر ویژگی‌های فردی، ارتباطات

غیرخطی بین ویژگی‌ها را نیز از طریق

طریق درهم‌تنیدگی


(Entanglement) کدگذاری می‌کند.

$$\tilde{\sigma}_{qnn}(h) = \left[\exp(i\theta_{h_0 h_1} Z_0 Z_1) \right] \cdot \left[RZ(\theta_{h_0}) \otimes RZ(\theta_{h_1}) \right]$$




طبقه‌بند QNN


- استفاده از درهم‌تنیدگی (Entanglement) برای کدگذاری داده‌ها
- ساختار سخت‌افزار-محور (Hardware-Efficient)
- ترکیب چرخش‌های Ry و گیت‌های CNOT



Real Amplitudes (Ansatz depth = 3)



Real Amplitudes (Ansatz depth = 5)



Real Amplitudes (Ansatz depth = 7)

$$V(\theta_c) = \prod_{l=1}^d \left[\bigotimes_{i=1}^{N'} \text{RY}(\theta_i^{(l)}) \text{RZ}(\theta_i'^{(l)}) \cdot \prod_{i=1}^{N'-1} \text{CNOT}_{i,i+1} \right]$$

$$y_{\text{pred}} = \begin{cases} 0 & \text{if } f_{\text{QCQ}} + b < \frac{1}{2}, \\ 1 & \text{otherwise,} \end{cases}$$

شبه کد آموزش مدل

```
1: Input: Training data  $\mathcal{D}_{\text{train}} = \{(x_i, y_i)\}$ , learning rate  $\eta$ , batch size  $s$ , total epochs  $T$ 
2: Output: Trained parameters  $\Theta^* = \{\phi^*, \theta_c^*\}$ 
3: for  $t = 1$  to  $T$  do
4:   for each mini-batch  $\mathcal{B} \subset \mathcal{D}_{\text{train}}$  of size  $s$  do
5:     Step 1: Quantum filter feature extraction (fixed)
6:     for each  $(x_i, y_i) \in \mathcal{B}$  do
7:       Extract image patches from  $x_i$ 
8:       Encode to quantum state:  $|\psi_{\text{in}}(x_i)\rangle = E(x_i)|0\rangle^{\otimes N}$ 
9:       Apply quantum filter:  $z_i = \text{Measure}[U_{\text{qconv}}|\psi_{\text{in}}(x_i)\rangle]$ 
10:    Step 2: Classical CNN feature encoding
11:    Compute latent representations  $h_i = f_{\text{cnn}}(z_i; \phi)$  for all  $z_i$  in batch
12:    Step 3: QNN classification
13:    for each  $h_i$  do
14:      Encode  $h_i$  to quantum state  $|\psi_{\text{qnn}}(h_i)\rangle$ 
15:      Apply QNN:  $|\psi_{\text{out}}\rangle = V(\theta_c)|\psi_{\text{qnn}}(h_i)\rangle$ 
16:      Compute output:  $f_i = \langle \psi_{\text{out}} | O | \psi_{\text{out}} \rangle$ 
17:      Compute loss:  $\ell_i = \text{CrossEntropy}(f_i, y_i)$ 
18:    Step 4: Optimization
19:    Update parameters  $\{\phi^{(t+1)}, \theta_c^{(t+1)}\}$  via Adam optimizer
20: return  $\Theta^* = \{\phi^*, \theta_c^*\}$ 
```

معرفی بنچمارک ها و رقبا

مجموعه‌های داده (Datasets)




MNIST

ارقام دست‌نویس (ساده)



Fashion-MNIST

تصاویر پوشاک (متوسط)



MRI Brain Tumor

تصاویر پزشکی تومور مغزی (پیچیده)

- MLP

- Quanvo + MLP

- Classical CNN

- QCCNN

- QCQ-CNN (مدل پیشنهادی) (VQC): دسته‌بند کوانتومی + CNN کلاسیک + دسته‌بند کوانتومی


شبکه تمام متصل کلاسیک

فیلتر کوانتومی + لایه کلاسیک



شبکه کانولوشنی کلاسیک

فیلتر کوانتومی + CNN کلاسیک + دسته‌بند کلاسیک


Model	MNIST (digits 3 vs 5)	FMNIST (T-shirt/trouser)	MRI brain tumor (benign/malignant)
MLP	96.56 $\pm$ 0.13	98.48 $\pm$ 0.11	86.10 $\pm$ 0.40
Quanvo + MLP	96.86 $\pm$ 0.14	98.58 $\pm$ 0.13	89.24 $\pm$ 0.85
CNN	98.79 $\pm$ 0.13	99.19 $\pm$ 0.19	89.43 $\pm$ 1.00
QCCNN	98.81 $\pm$ 0.25	99.28 $\pm$ 0.12	90.06 $\pm$ 1.00
QCQ-CNN	98.85 $\pm$ 0.25	99.41 $\pm$ 0.14	95.18 $\pm$ 0.65





MRI brain tumor



FMNIST



شبیه سازی با وجود نویز



- قابلیت اجرا روی کامپیوترهای کوانتومی فعلی

- حفظ دقت بالای ۹۵٪ حتی با وجود نویز

- شبیه سازی نویز واقعی سخت افزار (Depolarizing)

نتیجه‌گیری و کارهای آینده

