



۸۱۰۱۰۱۵۵۸

پردازش اطلاعات کوانتومی
نام و نام خانوادگی: مهدی وجهی



خلاصه مقاله
پروژه پایانی

۱ چکیده

محاسبات کوانتومی به علت پتانسیل بالای فضای هیلبرت با ابعاد بالا به خوبی در مدل های یادگیری عمیق می تواند استفاده شود. اما مواردی مانند محدودیت هایسخت افزار های کنونی، تعداد کیوبیت کم و نویز ها مشکلات کنونی این روش هستند. در روش این مقاله روشی هیبریدی به نام $QCC - CNN$ استفاده شده که یک لایه کوانتومی برای استخراج ویژگی های غیر خطی تصویر در ابتدا استفاده می کند سپس با استفاده از چند لایه کانولوشنی کلاسیک ویژگی های سطح بالاتر را استخراج می کند و در نهایت با استفاده از یک طبقه بند کوانتومی دسته بندی را انجام می دهد. این روش در مقایسه با سایر روش های کلاسیک و کوانتومی در دیتاست تصاویر تومور مغز به صورت قابل توجه بهتر است.


۲ معماری پیشنهادی

یک معماری سه مرحله ای تحت عنوان $QCC - CNN$ طراحی شده است که جریان داده در آن به صورت «کوانتومی $\rightarrow$ کلاسیک $\rightarrow$ کوانتومی» می باشد. هدف این معماری، بهره گیری از فضای هیلبرت برای استخراج ویژگی های اولیه و نهایی، و استفاده از شبکه های کلاسیک برای فشرده سازی اطلاعات است. در ادامه، جزئیات هر زیربخش تشریح می شود.

۱.۲ لایه کانولوشن کوانتومی

اولین لایه مدل، یک فیلتر کوانتومی (*Quantvolution*) است که وظیفه دارد تصاویر ورودی را به فضای ویژگی کوانتومی نگاشت کند. این لایه مشابه فیلترهای کانولوشن کلاسیک عمل می کند، با این تفاوت که عملیات ضرب ماتریسی با یک مدار کوانتومی جایگزین شده است. همچنین پارامترهای این لایه ثابت هستند و طبق گفته مقاله این موضوع تاثیر منفی ای ندارد و همچنین آموزش آن هم مشکلاتی دارد.

روش کار به این صورت است ما با $stride$ ۲ روی تصویر با پنجره 2×2 پیمایش می کنیم و به مدار ورودی می دهیم.



شکل ۱: نمای کلی شبکه عصبی هیبریدی

برای این که تصویر 2×2 را ورودی دهیم ابتدا مقدار آن را بین ۰ تا ۱ نرمالایز می کنیم و سپس برای کد کردن در کیوبیت با ضرب π در راستای y چرخش می دهیم. این باعث می شود که اگر پیکسل مقدار صفر داشته باشد کیوبیت $|0\rangle$ کد شود و اگر ۱ باشد $|1\rangle$ شود. این موضوع را به صورت زیر نوشت:

$$|\psi_{in}(x)\rangle = \bigotimes_{i=0}^3 RY(\pi x_i)$$

حال که کیوبیت ها مقدار دهی شد یکسری گیت تصادفی که ثابت هستند روی آنها اعمال می شود این گیت های چرخش حول دو محور y, z و همچنین گیت $CNOT$ هستند. این موضوع باعث ایجاد در هم تنیدگی و استخراج ویژگی های غیر خطی و همچنین روابط آن با پیکسل های مجاور آن می شود. به نوعی می توان به این بخش مثل یک کرنل غیر خطی نگاه کرد که تصویر 28×28 را به $14 \times 14 \times 4$ نگاشت می کند. می توان این گیت های تصادفی را با رابطه زیر نشان داد و پارمتر هایی که خط دارند یعنی مقدار ثابت دارند.

$$|\psi_{quav}(x)\rangle = \prod_{l=1}^L \left[\bigotimes_{i=0}^3 RZ(\bar{\theta}_{i,l}) RY(\bar{\theta}'_{i,l}) \cdot \prod_j CNOT_{j,j+1} \right] |\psi_{in}(x)\rangle$$

سپس مقدار مورد انتظار روی پاولی Z را روی هر ۴ کیوبیت اندازه می گیریم و این می شود خروجی مدار این قسمت.

۲.۲ شبکه عصبی کانولوشنال کلاسیک

خروجی لایه کوانتومی (که دارای ابعاد 14×14 با ۴ کانال است) وارد یک شبکه عصبی کلاسیک می‌شود. معماری این شبکه به شکل زیر است:


$$h = Dense_2 \circ Dense_1 \circ Pool_2 \circ Conv_2 \circ Pool_1 \circ Conv_1(z)$$

وجود لایه کلاسیک چندین دلیل دارد ابتدا این که ما تعداد کیوبیت های نویزی کمی داریم و نمی توانیم تعداد زیادی پیکسل یا ویژگی را همزمان در یک مدار کوانتومی وارد کنیم پس مجبوریم برای استخراج ویژگی های سطح بالاتر از کانولوشن کلاسیک استفاده کنیم. همچنین در مدار های کوانتومی همه گیت ها خطی هستند به غیر از اندازه گیری پس بنابر این برای ایجاد روابط غیر خطی ما به بخش کلاسیک نیاز داریم. آخر نکته هم این که در صورت بزرگ و عمیق شدن بخش کوانتومی با مشکل *Barren Plateaus* مواجه می شویم و محاسبه گرادیان صفر می شود و به مشکل می خورد و همچنین ویژگی های گرفته شده از لایه اول ابعاد زیادی دارند که لازم نیست و همچنین نویزی هستند ما با این لایه عملا این مشکلات را برطرف می کنیم و مدل را آموزش می دهیم که داده ها را به وسیله این بخش فشرده کند و نویز را حذف کند. با این کار عملا با $14 \times 14 \times 4$ ویژگی به ۲ ویژگی ورودی مدار کوانتومی بخش آخر تبدیل می کند.

۳.۲ طبقه بندی کننده کوانتومی (QNN)

آخرین مرحله، یک مدار کوانتومی قابل آموزش است که بردار ویژگی کاهش یافته ($h \in \mathbb{R}^2$) را دریافت کرده و کلاس نهایی را تعیین می‌کند. این بخش از دو جزء اصلی تشکیل شده است. بخش نقشه ویژگی که دو ویژگی را در دو کیوبیت کد می کند اما نکته این است که علاوه بر اعمال مجزا هر ویژگی روی محور z با اعمال مدار ZZ همبستگی ای بین آن دو ایجاد می کند که شدت آن مستقیماً به حاصل ضرب ویژگی ها بستگی دارد. این مدار باعث می شود شبکه بتواند روابط پیچیده بین دو ویژگی استخراج شده را درک کند. که شکل آن در مدار موجود است و معادله آن به شکل زیر است:

$$|\psi_{qnn}(h)\rangle = [\exp(i\theta h_0 h_1 Z_0 Z_1)] \cdot [RZ(\theta h_0) \otimes RZ(\theta h_1)] |0\rangle^{\otimes 2}$$



شکل ۲: مدار QNN

حال به بخش مدار *RealAmplitudes* می‌رسیم که عملاً حکم دسته‌بند ما را دارد که در هر مرحله طبق پارامترهای قابل آموزش چرخش در محور y انجام می‌دهیم و سپس روی نتیجه گیت *CNOT* اعمال می‌کنیم و بسته به عمق این کار را تکرار می‌کنیم. به نوعی گیت‌های چرخش حکم وزن‌های نورون را دارد و گیت *CNOT* حکم اتصالات در شبکه عصبی را دارد. لازم به ذکر است که مقاله بررسی کرده و عمق ۵ را پیشنهاد داده. سپس مقدار را می‌خوانیم و یک بایاس قابل یادگیری با آن جمع می‌زنیم و با شرط کمتر یا بیشتر بودن از $\frac{1}{2}$ دسته‌بندی را انجام می‌دهیم.

۳ نحوه آموزش

برای آموزش مدل ابتدا داده‌های مینی‌بچ خود را تک‌به‌تک از فیلتر کوانتومی رد می‌کنیم که ثابت است که مقدار z می‌شود و سپس از بخش کلاسیک کانولوشنی عبور می‌دهیم (به صورت یکجا) $(h = f_{cnn}(z; \phi))$ سپس تک‌به‌تک به دسته‌بند کوانتومی وارد می‌کنیم $(|\psi_{out}\rangle = V(\theta) |\psi_{qnn}(h_i)\rangle)$ سپس بعد از این که جواب محاسبه شد لاس متقاطع را برای بخش کلاسیک و دسته‌بند کوانتومی حساب می‌کنیم و در نهایت مقدار پارامترهای خود $\{\phi^{(t+1)}, \theta_c^{(t+1)}\}$ را با اپتیماایزر آدام برای گام بعد بروز می‌کنیم.

۴ تحلیل نتایج و مقایسه عملکرد

طبق نتایج بررسی در مجموعه داده *MNIST* و *Fashion - MNIST* این مدل از لحاظ دقت بهتر از سایر مدل‌های کلاسیک و کوانتومی است ولی تفاوت آن معنی‌دار نیست. اما در مجموعه داده پیچیده‌تر تشخیص تومور مغزی عملکرد خیره‌کننده‌ای دارد و نسبت به رقبا ۵ تا ۱۰ درصد بهتر عمل کرده. لازم به گفتن است که جهت برابری مدل‌ها تعداد پارامترهای آنها یکسان در نظر گرفته شده. همچنین این مدل نسبت به سایرین سرعت همگرایی بیشتری دارد و همچنین با اعمال نویز هم با این که سرعت یادگیری را کمی کم می‌کند اما در نهایت دقتی مشابه با مدل ایده‌آل می‌دهد. مورد آخر هم این که عمق مدار *RealAmplitudes* که موازنه بین آموزش پذیری و قدرت شبکه کوانتومی است با مقدار ۵ به تعادل خوبی می‌رسد و مقاله با مقادیر ۳ و ۷ آن را مقایسه کرده و نشان داده که بهتر است.

Model	MNIST (digits 3 vs 5)	FMNIST (T-shirt/trouser)	MRI brain tumor (benign/malignant)
MLP	96.56 ± 0.13	98.48 ± 0.11	86.10 ± 0.40
Quanvo + MLP	96.86 ± 0.14	98.58 ± 0.13	89.24 ± 0.85
CNN	98.79 ± 0.13	99.19 ± 0.19	89.43 ± 1.00
QCCNN	98.81 ± 0.25	99.28 ± 0.12	90.06 ± 1.00
QCQ-CNN	98.85 ± 0.25	99.41 ± 0.14	95.18 ± 0.65

شکل ۳: نتایج مقایسه در بنچ‌مارک‌ها